Resumo

Este trabalho se propõe a aplicar LLM-as-judge para feedbacks gerados por três LLMs open source, (Gemma 4, Qwen3:4b e Phi4-mini:3.8b), utilizando prompts padronizados, que para analisar uma amostra de disciplinas de tecnologia. Para o experimento, foram utilizados três prompts diferentes:

- base_prompt: utilizado como base, que agiria como um avaliador educacional e com regras simples, como domínio de escrita e proximidade semântica e conceitual. Ele também contém algumas regras de feedback, voltadas a identificar erros e imprecisões utilizando objetividade.
- nicol_prompt: neste prompt, utilizamos as boas práticas indicadas por Nicol & Macfarlane-Dick, permeando metas, promovendo autoavaliação, criando feedbacks construtivos, incentivadores de autoestima e buscando reduzir lacunas de desempenho.
- hattie_prompt: já neste prompt, utilizamos as boas práticas indicadas por Hattie & Timperley, passando pelo feed-up, feedback e feed-foward.

Cada um dos três modelos rodou os mesmos três prompts para uma amostra de 555 linhas, resultando em 1.665 feedbacks para cada modelo, com 4.995 feedbacks ao todo.

Ao fim desta amostragem, com o foco em avaliar objetivamente os resultados individuais dos modelos escolhidos, utilizamos uma LLM não open source para avaliar os resultados apresentados. Para este caso, utilizamos Gemini 2.5 Flash.

Para a rubrica de avaliação, levamos em consideração o feedback fornecido, a descrição da atividade utilizando o método de 16 dimensões para quantificar este feedback, indo de 0, quando a dimensão era ausente ou inadequada), 1 (quando a dimensão estava parcialmente presente) e 2 (quando a dimensão estava claramente presente e bem aplicada).

As dimensões foram divididas em 3 partes, sendo elas

PARTE 1 - CONTEÚDO DO FEEDBACK

1 - Alinhamento com objetivos

2 - Especificidade

3 - Tom motivacional

4 - Identificação de pontos fortes

5 - Identificação de pontos fracos

6 - Legibilidade

PARTE 2 - EFETIVIDADE DO FEEDBACK

7 - Feed-up

8 - Feedback

9 - Feed-foward

10 - Feedback sobre a tarefa

11 - Feedback sobre o processo

12 - Feedback sobre autorregulação

13 - Feedback sobre o eu

PARTE 3 - ALUCINAÇÕES

14 - Alucinação em conflito de entrada

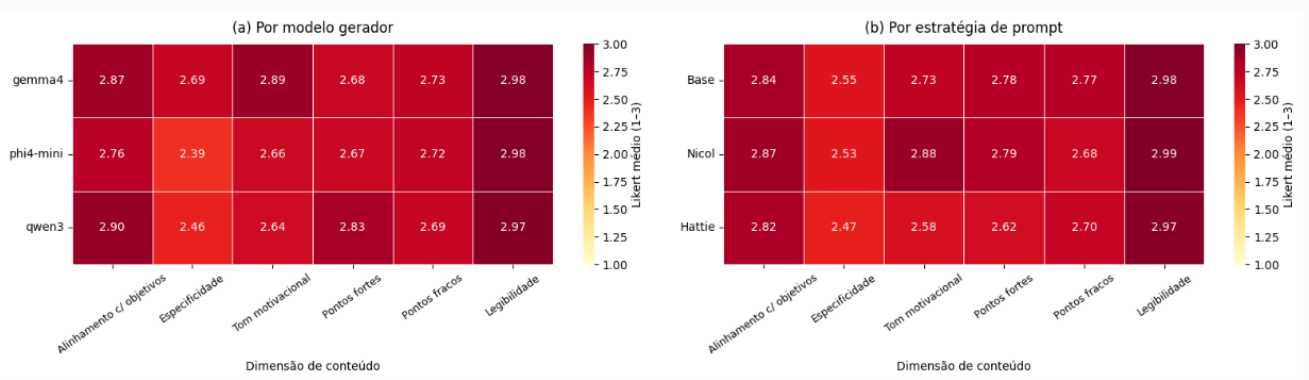
15 - Alucinação em conflito com o contexto

16 - Alucinação em conflito com fatos

Para poder avaliar em 16 dimensões propostas, utilizamos uma amostra que representa 25% do total analisado analisado, balanceadas entre os modelos.

Modelo	Prompt_Variant	Amostra
Gemma4	Base	156
	Hattie	180
	Nicol	164
Phi4-mini	Base	156
	Hattie	180
	Nicol	164
Qwen3	Base	156
	Hattie	180
	Nicol	164

Com as rubricas geradas para cada linha da amostra, geramos a média de resultados por modelos e a análise por dimensões de conteúdo. Com isso, conseguimos identificar:



Com o heatmap do conteúdo, conseguimos analisar a qualidade textual do feedback pelos pontos principais (alinhamentos com objetivo, especificidade, tom motivacional, pontos fortes, pontos fracos e legibilidade).

Observando por a) modelo gerados, vemos que o Qwen3 possui o melhor alinhamento e pontos fortes, porém um tom motivacional mais fraco. O Phi4-mini peca em especificidade (2,39), enquanto o Gemma4 possui o melhor tom motivacional e todos os resultados acima do Phi4-mini. Todos os modelos tiveram alta pontuação em legibilidade, demonstrando que são capazes de produzir textos claros, porém todos eles tiveram as menores pontuações em especificidade, demonstrando que podem ter maiores dificuldades em instruções mais detalhadas.

Já quando observamos por b) estratégia de prompt, observamos que Nicol possui o melhor tom motivacional e legibilidade, além de uma leve superioridade em alinhamentos com o objetivo. Já Hattie possui o pior tom motivacional e especificidade. O prompt de base possui bastante equilíbrio entre as dimensões de conteúdo.

Score Médio - Modelo x Prompt

Modelo	**Base**	**Hattie**	**Nicol**
Gemma4	1,43	1,45	1,49
Phi4-mini	1,40	1,32	1,39
Qwen3	1,36	1,33	1,45

As diferenças entre modelos são pequenas (~0,17 pontos entre o pior e melhor cenário. Globalmente, observamos que Nicol tende a ser um prompt melhor, especialmente para o Qwen3. Já Hattie, que mesmo não possuindo o pior resultado em todas as dimensões, demonstra ser o pior para Phi4-mini e Qwen3. O Gemma4, por outro lado, se mostra ligeiramente mais bem posicionado no

score global, mesmo que observando dimensões por conteúdo, ele não seja o maior pontuador em todas as dimensões.